

Benchmark reproductible de classification coloscopique : SE-ResNet sensible au masque et CNN-JEPA

Hamza AASSIF

Dynvibe

hamza@dynvibe.com

Résumé

L'analyse assistée par ordinateur des images de coloscopie peut aider au dépistage des polypes et au contrôle qualité, mais les données annotées restent rares et les protocoles d'évaluation sont fragmentés. Nous contribuons un **benchmark de classification coloscopique reproductible** : SE-ResNet-50 sensible au masque avec pré-entraînement JEPA convolutif (CNN-JEPA), scripts de préparation et protocole unifié (macro-F1, rappel par classe). Nous rapportons deux tâches complétées sur les données publiques Simula : (T3) dépistage trois classes (repère / muqueuse normale / polype ; C0–C10) et (T1) taxonomie fine HyperKvasir 23 classes (B2–B6). Nous comparons ResNet-50, SE-ResNet-50, fusion dual-stream et affinage CNN-JEPA sous les mêmes réglages d'entraînement. **Nous ne prétendons pas que le CNN-JEPA domaine bat le transfert ImageNet sur ces splits publics.** Sur T3 (split au niveau image, centre unique), ImageNet atteint macro-F1 0,989 et rappel polype 0,971 (C1), contre macro-F1 0,910 et rappel polype 0,829 pour l'affinage CNN-JEPA (C4). Sur T1, la macro-F1 $\approx 0,44$ – $0,59$ reflète un fort déséquilibre ; B6 dual-stream et B2 ResNet sont équivalents dans le bruit de mesure (0,586 vs 0,585). CNN-JEPA montre une *tendance* d'efficacité en labels sur T3 sans dépasser ImageNet aux fractions testées. Code, résultats JSON et tableaux LaTeX auto-générés publiés ; splits groupés et multi-seed sont des extensions prévues. **Mots-clés** : coloscopie, benchmark de classification, apprentissage auto-supervisé, JEPA, SE-ResNet, HyperKvasir.

1 Introduction

La coloscopie est l'examen de référence pour le dépistage du cancer colorectal. Les systèmes d'aide à la détection (CAD) analysent des images fixes pour signaler un polype suspect et confirmer les repères anatomiques requis par les scores de qualité. Les réseaux convolutifs conviennent au déploiement quasi temps réel, mais les résultats publiés restent difficiles à comparer entre architectures, régimes de pré-entraînement et définitions de tâches.

Les benchmarks publics mélangent détection binaire, dépistage trois classes agrégé et taxonomies multi-classes sans protocole ni code partagés. Le pré-entraînement auto-supervisé peut réduire le coût d'annotation, mais son avantage sur le transfert ImageNet en endoscopie reste une question empirique.

Les architectures prédictives jointes (JEPA) [6 ; 2] apprennent en prédisant des représentations latentes de vues masquées. Nous adaptons un JEPA *convolutif* aux frames coloscopiques avec des blocs SE sensibles au masque compatibles avec le masquage spatial.

En bref. Nous fournissons un **benchmark et une implémentation de référence reproductibles**—sans prétendre que le JEPA domaine bat ImageNet sur les données publiques Simula. La contribution principale est le protocole, le code et un rapport honnête sur les tâches complétées T3 (dépistage) et T1 (HyperKvasir-23).

Contributions. (1) **Méthode** : CNN-JEPA sur SE-ResNet-50 avec attention canal sensible au masque. (2) **Benchmark** : runs C0–C10 (T3) et B2–B6 (T1) reproductibles, arrêt anticipé,

métriques JSON et tableaux auto-générés. (3) **Étude empirique** : le transfert ImageNet surpasse le CNN-JEPA domaine sur les splits publics actuels ; nous documentons les tendances d’efficacité en labels et les ablations sans surestimer les gains.

2 Travaux connexes

Classification en endoscopie. Kvasir [7] et HyperKvasir [3] sont des références pour la classification d’images digestives. Un travail antérieur dans notre dépôt [1] compare ResNet-50, SE-ResNet-50 et fusion couleur–texture sur HyperKvasir (23 classes), avec une macro-F1 test $\approx 0,58$ – $0,59$ (B2–B6). Nous ciblons une taxonomie à *trois classes* alignée sur la pratique (repère, muqueuse, polype) plutôt que sur 23 labels académiques.

Attention canal. SE-Net [5] recalibre les canaux via une moyenne globale (GAP) puis excitation. Sous masquage JEPA, les zéros de padding biaisent la GAP ; nous proposons un pooling pondéré par le masque (section ??).

JEPA et auto-supervision. I-JEPA [2] repose sur des Vision Transformers ; nous employons un *CNN-JEPA* avec masquage par blocs et prédictor convolutif sur cartes de features—plus adapté au déploiement léger qu’un foundation model ViT. Nous ne prétendons pas inventer le pré-entraînement convolutif par prédiction latente ; notre originalité porte sur l’**intégration SE sensible au masque** et le **protocole de benchmark reproductible** pour la classification coloscopique. Des travaux proches incluent BYOL [4].

Détection de polypes. Les systèmes CAD [8] mettent l’accent sur la *sensibilité* aux polypes. Nous rapportons le rappel polype en plus de la macro-F1. La classe *polype* est unique (Kvasir + HyperKvasir polyps et dyed-lifted-polyps) ; le typage histologique est reporté aux travaux futurs.

2.1 Données et classes

T3 (dépistage). Fusion de Kvasir v1 et HyperKvasir en trois classes (repère, muqueuse normale, polype). Total : 9565 images, centre *simula*. Splits **groupés** par procédure/vidéo (`prepare-colonoscopy-3class` lit `image-labels.csv` HyperKvasir). Les images publiques actuelles sont une frame par groupe ; les groupes multi-frames s’appliquent avec les pools vidéo non annotés.

T1 (HyperKvasir-23). 23 dossiers officiels Simula ; 10 662 images, split 70/15/15.

Extensions prévues (hors tableaux principaux) : sous-ensemble pathologie-11 ; affinages JEPA sur HK-23.

2.2 Protocole expérimental

T3 (C0–C10). Dépistage trois classes ; fractions de labels C7–C9.

T1 (B2–B6). ResNet, SE-ResNet, dual-stream sur HyperKvasir-23 (supervisé uniquement dans ce manuscrit).

2.3 Métriques

Macro-F1 principale ; **rappel polype** = $TP / (TP + FN)$ pour la classe polype (sensibilité).

3 Expériences

Tâches complétées.

- **T3 (dépistage)** : trois classes coloscopiques (C0–C10), centre public unique *simula*.
- **T1 (fine)** : baselines supervisées HyperKvasir 23 classes (B2–B6).




FIGURE 1 – CNN-JEPA pretraining (top) and supervised fine-tuning (bottom). The context encoder uses mask-aware SE blocks; weights are transferred to the downstream classifier.

TABLE 1 – Three-class screening (T3) on Simula test split ($n = 1433$). Group-aware split (grouped); 3 seeds.

Method	Macro-F1	Polyp recall
SE-ResNet scratch	0.899	0.836
SE-ResNet ImageNet	0.989	0.971
ResNet-50 + CNN-JEPA	0.913	0.778
SE + CNN-JEPA (SE standard)	0.910	0.828
SE + CNN-JEPA (SE mask-aware)	0.910	0.828
SE + frozen teacher	0.910	0.828

Les extensions (pathologie-11, JEPA sur HK-23, sonde linéaire ViT) sont définies dans la feuille de route du dépôt mais *non rapportées* ici tant que les splits groupés et multi-seed ne sont pas terminés.

Matériel. Apple MPS (AMD Radeon Pro 5300M).

Pré-entraînement (CNN-JEPA). Jusqu’à 4 000 frames non annotées (proxy : images d’entraînement étiquetées si corpus non annoté indisponible); checkpoints partagés pour C2–C5. Prévu : ~ 99 k images fixes HyperKvasir pour un pré-entraînement domaine.

Affinage. Batch 16, AdamW lr 10^{-4} (ImageNet / JEPA) ou 10^{-3} (scratch), taille 224; arrêt anticipé sur macro-F1 validation.

Hypothèses (exploratoires, non confirmées). H1 : C4 bat C1 sous labels limités. H2 : C4 bat C3 (SE sensible au masque). H3 : $C4 \geq C5$ à 25 % de labels. Aucune n’est soutenue sur les splits publics par image actuels sans réévaluation groupée.

4 Résultats

4.1 Dépistage trois classes (T3)

Le tableau 1 résume la comparaison principale sur le split test Simula. ImageNet (C1) obtient la meilleure macro-F1 (0,989) et le meilleur rappel polype (0,971). C4 (CNN-JEPA + SE sensible au masque) atteint macro-F1 0,910 et rappel polype 0,829. Le scratch (C0) est légèrement inférieur (macro-F1 0,899).

Ablations. C3, C4 et C5 sont identiques (macro-F1 0,910) sur ce fold ; le gain du SE sensible au masque n’est pas mesurable ici.

Efficacité en labels. La macro-F1 de C4 progresse de 0,825 (10 %) à 0,907 (50 %) et 0,910 (100 %), mais reste sous C1.

TABLE 2 – Label-efficiency curve for C4 (mask-aware SE + CNN-JEPA).

Setting	Macro-F1	Polyp recall
ImageNet (100% labels)	0.989	0.971
C4 (100% labels)	0.910	0.828
C4 @ 10% labels	0.825	0.726
C4 @ 25% labels	0.871	0.712
C4 @ 50% labels	0.907	0.723

TABLE 3 – HyperKvasir 23-class supervised baselines (T1, test split). Prior work on this dataset reports macro-F1 ≈ 0.55 – 0.60 for ResNet-style fine-tuning.

Run	Architecture	Pretrain	Macro-F1	Acc.
B2	ResNet-50	ImageNet	0.585	0.879
B3	SE-ResNet-50	scratch	0.439	0.725
B4	SE-ResNet-50	ImageNet	0.577	0.882
B5	Dual-stream	scratch	0.448	0.755
B6	Dual-stream	ImageNet	0.586	0.888

4.2 HyperKvasir 23 classes (T1)

Le tableau 3 rapporte les baselines supervisées B2–B6. La macro-F1 varie d’environ 0,44 à 0,59 tandis que l’accuracy dépasse 0,87 (déséquilibre des classes). B6 et B2 diffèrent de 0,001 en macro-F1 (0,586 vs 0,585)—bruit d’un seul run ; une évaluation multi-seed est nécessaire.

Confusions (T3). Pour C4, les erreurs polype concernent surtout les repères (12,4 %) et la muqueuse normale (4,7 %) — figure 3.

Mise en garde sur les splits. Les chiffres T3 actuels utilisent des splits stratifiés par image (pas groupés par procédure) ; la macro-F1 de C1 peut être optimiste.

5 Discussion

Contribution méthodologique vs empirique. Nous séparons le *pipeline* (CNN-JEPA + SE sensible au masque + protocole T1/T3 unifié) des *gains empiriques* sur les données publiques Simula. Le pipeline est réutilisable lorsque vidéos non annotées et labels multi-centres seront disponibles ; les chiffres actuels ne soutiennent pas la supériorité sur ImageNet pour le dépistage (T3).

Difficulté des tâches et métriques. La macro-F1 absolue chute d’environ 0,99 (T3, C1) à environ 0,58 (T1, B6) avec l’augmentation du nombre de classes et de l’hétérogénéité clinique. L’accuracy peut dépasser la macro-F1 de plus de 30 points sur les tâches déséquilibrées ; macro-F1 et rappel par classe restent obligatoires.

Pourquoi ImageNet gagne sur T3. Les images publiques Simula restent proches des statistiques d’images naturelles où le pré-entraînement ImageNet excelle. Avec un seul centre, le LOO strict se réduit à un split poolé—interpréter avec prudence jusqu’à l’ajout de centres privés.

Implications cliniques. Le rappel polype passe de 97 % (C1) à 83 % (C4) sur T3—insuffisant pour un déploiement dépistage sans amélioration. Les tâches fine et pathologie ciblent d’autres workflows cliniques, pas le remplacement de l’histologie.

Histologie des polypes. Le sous-typage endoscopique (adénome vs hyperplasique) nécessite ERCPMP ou PIBAdb ; intégration documentée dans la feuille de route classification.

TABLE 4 – Per-class metrics for C4 on T3 test.

Class	Precision	Recall	F1
Landmark	0.940	0.930	0.930
Normal mucosa	0.890	0.990	0.940
Polyp	0.900	0.830	0.860




FIGURE 2 – Label-efficiency curve on the Simula fold. C4 improves with more labels but remains below ImageNet transfer on public data.

Reproductibilité. Scripts de campagne, configurations d’arrêt anticipé et JSON versionnés; tableaux auto-générés via `generate_paper_tables.py`.

5.1 Limites

Données et splits. Tous les résultats T3 proviennent d’un centre public unique (**simula**) et de 9565 images fusionnées Kvasir/HyperKvasir. Les splits groupés sont implémentés, mais les images étiquetées publiques actuelles sont une frame par groupe; la fuite multi-frames vidéo peut apparaître avec les pools non annotés. **Pré-entraînement.** Le CNN-JEPA utilise jusqu’à 4 000 frames (proxy train étiqueté si le corpus ~ 99 k non annoté est indisponible). **Incertitude.** Les tableaux rapportent un seed unique ou moyenne $\pm$ écart-type; intervalles bootstrap et tests de significativité sont prévus. **Portée clinique.** Métriques frame-level, pas sensibilité vidéo à spécificité fixée; validation prospective nécessaire au déploiement. **Calcul.** Expériences sur Apple MPS (AMD Radeon Pro 5300M); temps et énergie non benchmarkés ici.

6 Conclusion

Nous avons présenté un cadre CNN-JEPA sur SE-ResNet-50 sensible au masque et un **benchmark de classification coloscopique reproductible** pour le dépistage (3 classes) et HyperKvasir-23 (T1). Sur les données publiques Simula, le transfert ImageNet reste la référence pour le dépistage; les tâches fines montrent une macro-F1 $\approx 0,58$ avec B6 dual-stream en tête des runs supervisés. CNN-JEPA est compétitif face au scratch sur T3 mais ne valide pas encore l’hypothèse H1. Perspectives : histologie des polypes (ERCPMP, PIBAdb), vidéo non annotée réelle, LOO multi-centres privés, sonde linéaire ViT.

Remerciements

Nous remercions les équipes Simula/Kvasir pour les jeux de données publics.




FIGURE 3 – Row-normalized confusion matrix for C4 on test ($n = 1433$). Primary clinical concern : polyp recall 82.8%.

Références

- [1] Hamza AASSIF. Comparative architectures for endoscopy classification : Resnet, se-resnet, and dual-stream fusion. *endoscopy-resnet repository*, 2026. Internal benchmark report B2–B6.
- [2] Mahmoud Assran et al. Self-supervised learning from images with a joint-embedding predictive architecture. In *CVPR*, 2023.
- [3] Hanna Borgli, Vajira Thambawita, Petter Halvorsen Smedsrud, et al. Hyperkvasir, a comprehensive multi-class image and video dataset for gastrointestinal endoscopy. *Scientific Data*, 7 :283, 2020.
- [4] Jean-Bastien Grill, Florian Strub, et al. Bootstrap your own latent : A new approach to self-supervised learning. *NeurIPS*, 2020.
- [5] Jie Hu, Li Shen, and Gang Sun. Squeeze-and-excitation networks. In *CVPR*, 2018.
- [6] Yann LeCun. A path towards autonomous machine intelligence. *OpenReview*, 2022.
- [7] Konstantin Pogorelov, Magnus Randel, Kristoffer Johansen, et al. Kvasir : A multi-class image dataset for computer aided gastrointestinal disease detection. In *MMM*, 2017.
- [8] Nima Tajbakhsh, Suryakanth R Gurudu, et al. Automated polyp detection in colonoscopy videos using shape and context information. *IEEE Transactions on Medical Imaging*, 35(2) : 630–644, 2016.