

SE-ResNet sensible au masque avec pré-entraînement CNN-JEPA pour la classification de frames coloscopiques sous faible supervision

Hamza AASSIF
Dynvibe
hamza@dynvibe.com

Résumé

L'analyse assistée par ordinateur des images de coloscopie peut aider à repérer les polypes et à contrôler la qualité de l'examen, mais les données annotées restent rares et les modèles généralisent mal d'un centre hospitalier à l'autre. Nous proposons une architecture prédictive jointe *convolutive* (CNN-JEPA, *Joint-Embedding Predictive Architecture*) appliquée à un SE-ResNet-50 avec blocs SE *sensibles au masque* : l'attention canal ne porte que sur les pixels *visibles* sous masquage par blocs. Après un pré-entraînement non supervisé sur des frames non annotées, nous affinons un modèle sur trois classes cliniques : *repère anatomique*, *muqueuse normale* et *polype* (classe unique, sans sous-types histologiques). Nous rapportons une matrice reproductible C0–C10 avec arrêt anticipé strict sur les données publiques Simula (Kvasir + HyperKvasir, 9565 images). Sur le fold public disponible, le transfert ImageNet (macro-F1 0,989 ; rappel polype 0,971) surpasse l'affinage CNN-JEPA domaine (C4 : macro-F1 0,910 ; rappel polype 0,829). CNN-JEPA reste compétitif face à l'entraînement from scratch et montre une tendance d'efficacité en labels (macro-F1 0,825–0,907 pour 10–50 %), sans dépasser ImageNet sur les seules données publiques. Code et protocoles publiés pour une évaluation multi-centres (leave-one-center-out). **Mots-clés** : coloscopie, détection de polype, apprentissage auto-supervisé, JEPA, SE-ResNet.

1 Introduction

La coloscopie est l'examen de référence pour le dépistage du cancer colorectal. Les systèmes d'aide à la détection (CAD) analysent des images fixes pour signaler un polype suspect et confirmer les repères anatomiques (cæcum, iléon) requis par les scores de qualité. Les réseaux convolutifs conviennent au déploiement quasi temps réel, mais exigent beaucoup d'annotations et sur-apprennent souvent l'apparence d'un seul centre.

L'apprentissage auto-supervisé peut réduire le coût d'annotation en pré-entraînant sur des vidéos non étiquetées. Les architectures prédictives jointes (JEPA) [6 ; 2] apprennent en prédisant des représentations latentes de vues masquées, sans reconstruction pixel à pixel. Des variantes JEPA existent en imagerie médicale (échographie, IRM), mais pas pour la coloscopie avec des CNN légers déployables en salle.

En bref. Nous fournissons un pipeline ouvert et reproductible : pré-entraînement CNN-JEPA sur frames coloscopiques, blocs SE sensibles au masque compatibles avec le masquage JEPA, et un benchmark à trois classes cliniques (repère / muqueuse normale / polype) avec courbe d'efficacité en labels et protocole leave-one-center-out. Nous ne prétendons pas battre ImageNet sur les données publiques Simula ; nous rapportons les résultats honnêtement et publions le code.

Contributions. (1) **Méthode** : JEPA convolutif (CNN-JEPA) sur SE-ResNet-50 pour frames non annotées. (2) **Technique** : blocs SE sensibles au masque avec moyenne globale pondérée par le masque spatial. (3) **Évaluation** : benchmark C0–C10 reproductible, fractions de labels (10/25/50 %), cadre LOO multi-centres (un centre public disponible à ce jour).

2 Travaux connexes

Classification en endoscopie. Kvasir [7] et HyperKvasir [3] sont des références pour la classification d’images digestives. Un travail antérieur dans notre dépôt [1] compare ResNet-50, SE-ResNet-50 et fusion couleur-texture sur HyperKvasir (23 classes), avec une macro-F1 test $\approx 0,58-0,59$ (B2-B6). Nous ciblons une taxonomie à *trois classes* alignée sur la pratique (repère, muqueuse, polype) plutôt que sur 23 labels académiques.

Attention canal. SE-Net [5] recalibre les canaux via une moyenne globale (GAP) puis excitation. Sous masquage JEPA, les zéros de padding biaisent la GAP ; nous proposons un pooling pondéré par le masque (section 3.2).

JEPA et auto-supervision. I-JEPA [2] repose sur des Vision Transformers ; nous employons un *CNN-JEPA* avec prédicteur convolutif sur cartes de features, plus adapté au déploiement léger qu’un foundation model ViT. Des travaux proches incluent BYOL [4]. Le pré-entraînement JEPA coloscopique sur CNN reste, à notre connaissance, non couvert.

Détection de polypes. Les systèmes CAD [8] mettent l’accent sur la *sensibilité* aux polypes. Nous rapportons le rappel polype en plus de la macro-F1. La classe *polype* est unique (Kvasir + HyperKvasir *polyps* et *dyed-lifted-polyps*) ; le typage histologique est reporté aux travaux futurs.

3 Méthodes

3.1 Pré-entraînement CNN-JEPA

Soit une frame non annotée x et un masque binaire par blocs m . L’*encodeur contexte* f_θ (SE-ResNet-50) produit une carte de features $h = f_\theta(x \odot m, m)$. Un *prédicteur* convolutif g_ϕ prédit $\hat{z} = g_\phi(h)$. Un *encodeur cible* $f_{\bar{\theta}}$ (copie EMA, $\tau = 0,996$) encode l’image complète : $z = f_{\bar{\theta}}(x)$. La perte est l’erreur quadratique moyenne sur représentations normalisées :

$$\mathcal{L}_{\text{JEPA}} = \|\text{norm}(\hat{z}) - \text{norm}(z)\|_2^2. \quad (1)$$

Les masques laissent visibles 25–45 % des pixels. Arrêt anticipé sur la perte latente de validation (patience 10, max 80 époques).

3.2 SE sensible au masque

Les blocs SE classiques utilisent une GAP sur toute l’image. Notre **SE sensible au masque** ne moyenne que les positions visibles :

$$\text{GAP}_c(x, m) = \frac{\sum_{i,j} x_{c,i,j} m_{i,j}}{\sum_{i,j} m_{i,j} + \epsilon}. \quad (2)$$

L’ablation C3 garde un SE standard ; C4 active le SE sensible au masque.

3.3 Données et classes

Fusion de Kvasir v1 et HyperKvasir en trois classes :

- **Repère anatomique** : cæcum, pylore, z-ligne, iléon, rétroflexions.
- **Muqueuse normale** : scores BBPS, hémorroïdes, selles impactées.
- **Polype** : Kvasir *polyp*, HyperKvasir *polyps* et *dyed-lifted-polyps*.

Pathologies exclues (Barrett, colite ulcéreuse, œsophagite). HyperKvasir ne fournit *pas* de sous-types histologiques de polypes. Total : 9565 images, centre **simula**.




FIGURE 1 – CNN-JEPA pretraining (top) and supervised fine-tuning (bottom). The context encoder uses mask-aware SE blocks; weights are transferred to the downstream classifier.

TABLE 1 – Main benchmark comparison on the Simula fold (test split, $n = 1433$).

Method	Macro-F1	Polyp recall
--------	----------	--------------

3.4 Protocole C0–C10

C0 scratch ; C1 ImageNet ; C2 ResNet + JEPA ; C3/C4 SE + JEPA (SE standard vs sensible au masque) ; C5 enseignant figé ; C7–C9 fractions de labels ; C10 agrégat LOO pour C4. Sélection du checkpoint par macro-F1 validation (patience 5, max 30 époques).

3.5 Métriques

Macro-F1 principale ; **rappel polype** secondaire (dimension clinique).

3.6 Implémentation

PyTorch sur Apple MPS ; dépôt `endoscopy-resnet` ; campagne `run_full_jepa_benchmarks.sh`.

4 Expériences

Matériel. Apple MPS ; campagne complète $\approx 24,5$ h.

Pré-entraînement. Jusqu’à 4,000 frames (proxy si vidéo non annotée indisponible) ; arrêt anticipé à l’époque 20.

Affinage. Batch 16, AdamW, images 224×224 ; test : 1,433 images (15 % par classe, graine 42).

Hypothèses. H1 : C4 bat C1 avec peu de labels ; H2 : C4 bat C3 ; H3 : $C4 \geq C5$ à 25 % de labels.

Note LOO. Un seul centre public ; l’évaluation LOO stricte multi-centres attend des données privées dans `data/private/`.

5 Résultats

Le tableau 1 résume la comparaison principale sur le split test Simula. ImageNet (C1) obtient la meilleure macro-F1 (0,989) et le meilleur rappel polype (0,971). C4 (CNN-JEPA + SE sensible au masque) atteint macro-F1 0,910 et rappel polype 0,829. Le scratch (C0) est légèrement inférieur (macro-F1 0,899).

TABLE 2 – Label-efficiency curve for the proposed method (C4 backbone).




FIGURE 2 – Label-efficiency curve on the Simula fold. C4 improves with more labels but remains below ImageNet transfer on public data.

Ablations. C3, C4 et C5 sont identiques (macro-F1 0,910) sur ce fold ; le gain du SE sensible au masque n’est pas mesurable ici.

Efficacité en labels. La macro-F1 de C4 progresse de 0,825 (10 %) à 0,907 (50 %) et 0,910 (100 %), mais reste sous C1.

Confusions. Pour C4, les erreurs polype concernent surtout les repères (12,4 %) et la muqueuse normale (4,7 %) — figure 3.

LOO. Macro-F1 moyenne C10 pour C4 : 0,910 ($n = 1$ fold).

6 Discussion

Apport méthodologique vs empirique. Le pipeline (CNN-JEPA + SE sensible au masque + protocole C0–C10) est réutilisable ; les chiffres actuels sur Simula ne démontrent pas la supériorité sur ImageNet.

Pourquoi ImageNet domine. Les images publiques peuvent rester proches de statistiques naturelles favorisant ImageNet ; avec un seul centre, le LOO strict se dégrade en split poolé.

Implications cliniques. Rappel polype 83 % (C4) vs 97 % (C1) — insuffisant pour un déploiement de dépistage sans amélioration (perte focalisée, pré-entraînement vidéo réel, multi-centres).

Typage des polypes. Classe *polype* unique ; le typage endoscopique ou histologique (adénome, hyperplasique, classification de Paris) nécessitera d’autres jeux de données — perspective de travail futur.

Comparaison 23 classes. Les benchmarks HyperKvasir B2–B6 ($\approx 0,58$ macro-F1) concernent une tâche plus fine ; notre regroupement en 3 classes vise d’autres décisions cliniques.

Reproductibilité. Tableaux générés automatiquement depuis les JSON de benchmark.

7 Conclusion

Nous avons présenté un cadre CNN-JEPA sur SE-ResNet-50 sensible au masque pour la classification de frames coloscopiques, avec un benchmark reproductible à trois classes. Sur les données publiques Simula, le transfert ImageNet reste la référence la plus forte ; CNN-JEPA est compétitif face au scratch mais ne valide pas encore l’hypothèse H1. Perspectives : vidéo non




FIGURE 3 – Row-normalized confusion matrix for C4 on test ($n = 1433$). Primary clinical concern : polyp recall 82.8%.

annotée réelle, folds LOO multi-centres privés, typage des polypes, comparaison à une sonde linéaire sur foundation model ViT.

Remerciements

Nous remercions les équipes Simula/Kvasir pour les jeux de données publics.

Références

- [1] Hamza AASSIF. Comparative architectures for endoscopy classification : Resnet, se-resnet, and dual-stream fusion. *endoscopy-resnet repository*, 2026. Internal benchmark report B2–B6.
- [2] Mahmoud Assran et al. Self-supervised learning from images with a joint-embedding predictive architecture. In *CVPR*, 2023.
- [3] Hanna Borgli, Vajira Thambawita, Petter Halvorsen Smedsrud, et al. Hyperkvasir, a comprehensive multi-class image and video dataset for gastrointestinal endoscopy. *Scientific Data*, 7 :283, 2020.
- [4] Jean-Bastien Grill, Florian Strub, et al. Bootstrap your own latent : A new approach to self-supervised learning. *NeurIPS*, 2020.
- [5] Jie Hu, Li Shen, and Gang Sun. Squeeze-and-excitation networks. In *CVPR*, 2018.
- [6] Yann LeCun. A path towards autonomous machine intelligence. *OpenReview*, 2022.
- [7] Konstantin Pogorelov, Magnus Randel, Kristoffer Johansen, et al. Kvasir : A multi-class image dataset for computer aided gastrointestinal disease detection. In *MMM*, 2017.
- [8] Nima Tajbakhsh, Suryakanth R Gurudu, et al. Automated polyp detection in colonoscopy videos using shape and context information. *IEEE Transactions on Medical Imaging*, 35(2) : 630–644, 2016.