

Revue comparative des architectures pour la classification endoscopique multi-classes :

ResNet-50, SE-ResNet-50 et dual-stream couleur-texture

Hamza AASSIF

Recherche indépendante — projet *endoscopy-resnet*

Juin 2026

RÉSUMÉ

Contexte. La classification automatique d'images endoscopiques digestives exige des architectures capables de discriminer repères anatomiques, lésions pathologiques, procédures teintées et indicateurs de qualité procédurale, dans des conditions d'éclairage et de coloration très variables.

Objectif. Comparer systématiquement trois familles d'architectures — **ResNet-50** (baseline mono-flux RGB), **SE-ResNet-50** (recalibrage canal par blocs Squeeze-and-Excitation) et **dual-stream couleur-texture** (fusion ResNet-50 RGB + branche HSV/LBP) — sur la taxonomie complète **HyperKvasir (23 classes)**, en régimes *from scratch* et *fine-tune ImageNet*.

Méthodes. Protocole benchmark B0–B6 documenté : B0/B1 sur Kvasir v1 (4 classes, résultats réels) ; B2–B6 sur HyperKvasir (splits stratifiés 70/15/15, seed 42). Métrique principale : macro-F1. Sélection des checkpoints par validation macro-F1 maximale.

Résultats. Sur **Kvasir v1**, le baseline B0 atteint **70,3 % d'exactitude** et **0,689 macro-F1** (test) ; B1 (Optuna) atteint **76,0 %** et **0,749 macro-F1**. Sur **HyperKvasir (23 classes)**, les campagnes B2–B6 donnent (test) : B2 87,9 % / F1 0.585, B3 72,5 % / F1 0.439, B4 88,2 % / F1 0.577, B5 75,5 % / F1 0.448, B6 88,8 % / F1 0.586.

Conclusions. Sur HyperKvasir, le **SE-ResNet-50 ImageNet (B4)** atteint **88,2 % d'exactitude** et **0,577 macro-F1** (test), légèrement sous le ResNet-50 ImageNet (B2 : 0,585) et le dual-stream ImageNet (B6 : 0,586). En scratch, le SE-ResNet (B3, F1 0,439) reste nettement inférieur au transfer learning. Sur Kvasir v1, le rappel polype (~48 %) reste insuffisant cliniquement. Cette revue v1.1 intègre l'intégralité du plan et les résultats HyperKvasir B2–B6.

Mots-clés : *endoscopie digestive, HyperKvasir, ResNet, SE-ResNet, dual-stream, couleur-texture, LBP, classification multi-classes, macro-F1, apprentissage par transfert, aide au diagnostic.*

1. Introduction

1.1 Motivation clinique

Le cancer colorectal demeure une cause majeure de morbidité et de mortalité. L'efficacité de la coloscopie repose sur l'inspection complète de la muqueuse, la confirmation de l'intubation cœcale, le taux de détection des adénomes (ADR) et la documentation des repères anatomiques. Les systèmes d'aide à la détection (CAD) analysent les images en temps réel ou différé pour repérer polypes, inflammations, œsophagites, scores de préparation (BBPS) et repères procéduraux.

Les jeux publics **Kvasir** et **HyperKvasir** ont permis de standardiser l'évaluation des réseaux convolutifs sur l'imagerie digestive. HyperKvasir étend Kvasir à **23 classes** couvrant l'ensemble du tractus gastro-intestinal, avec un déséquilibre de classes reflétant la prévalence clinique réelle.

1.2 Limites du ResNet-50 mono-flux actuel

Le dépôt *endoscopy-resnet* expose actuellement un **ResNet-50 from scratch mono-flux RGB** sur 4 classes Kvasir v1. Les résultats réels (juin 2026) montrent une exactitude test de 76 % (B1) mais un **rappel polype de 48 %**, insuffisant pour un déploiement clinique. Les limites identifiées sont :

- **Mono-modalité RGB** — les textures muqueuses (polype vs ulcère) et les variations de couleur (sang, bile, luminosité) ne sont pas explicitement modélisées.
- **Périmètre 4 classes** — ne couvre pas la richesse taxonomique HyperKvasir (œsophagites, Barrett, grades colite, BBPS, procédures teintées).
- **Absence de recalibrage canal** — pas de mécanisme d'attention intra-feature (SE) pour pondérer les canaux selon le contexte endoscopique.
- **Pas de pré-entraînement ImageNet** — la condition B2 (transfer learning) n'était pas implémentée au moment des benchmarks Kvasir v1.
- **Instabilité MPS** — entraînements longs sur GPU Apple MPS sujets à corruption de checkpoints.

1.3 Questions de recherche (RQ1–RQ6)

ID	Question
RQ1	Un ResNet-50 from scratch peut-il établir une baseline fiable sur un protocole standardisé (Kvasir v1, 4 classes) ?
RQ2	L'optimisation Optuna (B1) améliore-t-elle la macro-F1 par rapport aux hyperparamètres par défaut (B0) ?
RQ3	Le SE-ResNet-50 (recalibrage canal) surpasse-t-il le ResNet-50 sur HyperKvasir (23 classes), en scratch (B3) et ImageNet (B4) ?
RQ4	Le dual-stream couleur-texture (RGB + HSV/LBP) améliore-t-il la macro-F1 par rapport aux architectures mono-flux (B5/B6 vs B2/B3) ?
RQ5	Le fine-tune ImageNet améliore-t-il systématiquement les performances par rapport au scratch pour chaque architecture (B2 vs B0, B4 vs B3, B6 vs B5) ?
RQ6	Les résultats internes sont-ils comparables à l'état de l'art publié sous protocole équivalent (splits, classes, pré-entraînement, métrique) ?

1.4 Apports de cette étude

- Comparaison systématique de **trois architectures** × **deux régimes d'entraînement** sur HyperKvasir.
- Protocole reproductible B0–B6 avec métriques cliniquement pertinentes (macro-F1, rappel par classe, macro-rappel groupé).
- Baseline interne documentée sur Kvasir v1 (B0 70,3 % / B1 76,0 % test accuracy).
- Pipeline Pixi, registre de modèles extensible et checkpoints enrichis.

2. État de l’art

Le tableau suivant synthétise les travaux de référence et notre baseline interne. Les comparaisons directes sont limitées par des protocoles hétérogènes (splits, classes regroupées, métriques).

Tableau 1 — Synthèse comparative de l’état de l’art en classification endoscopique.

Référence	Approche	Jeu / classes	Résultat rapporté	Pertinence
Hu et al. 2018 (SE-Net)	SE-ResNet, recalibrage canal	ImageNet	+0,9 pp top-1 vs ResNet	Base théorique des blocs SE
SE-ResNet + Kvasir v2 (IIETA 2024)	SE-ResNet + optimisation	Kvasir v2, 8 classes	~99,7 % accuracy	Même domaine GI ; protocole différent (feature selection)
Borgli et al. 2020 (HyperKvasir)	Benchmark dataset	23 classes, 10 662 images	Référence taxonomique	Jeu cible de cette étude
Effimix / EfficientNet fusion (MDPI 2022)	Dual CNN + fusion features	HyperKvasir multi-classes	~98 % accuracy	Concurrent dual-stream à citer
Hybrid LBP+GLCM+RGB (Sensors 2022)	CNN + descripteurs texture/couleur	Maladies GI	~99 % (FFNN)	Justifie branche texture explicite
FRAN dual-branch (2024)	Attention résiduelle + fusion contours	Kvasir / HyperKvasir	97 %+	Fusion sémantique + détail spatial
Baseline interne (juin 2026)	ResNet-50 scratch + Optuna	Kvasir v1, 4 classes	B0 test 70,3 % acc, 0,689 F1 B1 test 76,0 % acc, 0,749 F1	Point de départ interne documenté

Limites de comparaison directe. Splits différents, pré-entraînement variable, classes regroupées ou non, métriques parfois accuracy seule sur jeux équilibrés. Notre protocole impose **macro-F1**, **rappel par classe**, **matrice de confusion** et splits fixes documentés (seed 42).

3. Taxonomie HyperKvasir (23 classes)

Les 23 classes officielles Simula sont organisées par groupe clinique. **Exclusion explicite** : pas de sous-types histologiques de polypes (hyperplasique vs adénomateux) — non présents dans les labels HyperKvasir.

3.1 Repères anatomiques (6 classes)

- `normal-cecum` — cæcum normal (repère de fin de coloscopie)
- `normal-pylorus` — pylore normal
- `normal-z-line` — ligne Z œsogastrique
- `ileum` — iléon (endoscopie poussée)
- `retroflex-rectum` — rétroflexion rectale
- `retroflex-stomach` — rétroflexion gastrique

3.2 Polypes et procédures teintées (3 classes)

- `polyp` — polype non teint
- `dyed-lifted-polyps` — polype soulevé par injection + teinture
- `dyed-resection-margins` — marges de résection teintées

3.3 Inflammation et pathologies (12 classes)

- `oesophagitis-a` — œsophagite grade A (Los Angeles)
- `oesophagitis-b-d` — œsophagite grades B–D
- `barretts` — œsophage de Barrett
- `short-segment-barretts` — Barrett court segment
- `ulcerative-colitis-0-1` — colite ulcéreuse score 0–1 (Mayo endoscopique)
- `ulcerative-colitis-1-2` — colite ulcéreuse score 1–2
- `ulcerative-colitis-2-3` — colite ulcéreuse score 2–3
- `ulcerative-colitis-grade-1` — colite ulcéreuse grade 1
- `ulcerative-colitis-grade-2` — colite ulcéreuse grade 2
- `ulcerative-colitis-grade-3` — colite ulcéreuse grade 3
- `hemorrhoids` — hémorroïdes
- `impacted-stool` — fécalome / résidu fécal


3.4 Qualité et préparation (2 classes)

- `bbps-0-1` — score BBPS 0–1 (préparation insuffisante)
- `bbps-2-3` — score BBPS 2–3 (préparation adéquate)

3.5 Regroupements pour le reporting

En complément des 23 classes fines, un **macro-rappel groupé** sera calculé : repères anatomiques / pathologies / procédures teintées / scores qualité — pour l'analyse clinique agrégée dans

Figure 2 — Échantillons HyperKvasir par groupe clinique.



4. Architectures proposées

4.1 ResNet-50 baseline (B0 / B1 / B2)


Architecture de référence : ResNet-50 avec blocs Bottleneck (expansion 4), ~23,5 M paramètres, entrée RGB 224×224, sortie softmax à N classes.

- **B0** — from scratch, hyperparamètres par défaut (AdamW, $lr=10^{-3}$, 15 époques). Évalué sur Kvasir v1 (4 classes).
- **B1** — from scratch + Optuna HPO (8 essais, objectif macro-F1 validation). Évalué sur Kvasir v1.
- **B2** — fine-tune ImageNet (torchvision ResNet-50 pré-entraîné, $lr=10^{-4}$). Évalué sur HyperKvasir (23 classes).

4.2 SE-ResNet-50 (B3 / B4)

Extension du ResNet-50 par blocs **Squeeze-and-Excitation** (Hu et al., 2018). Chaque SEBottleneck intègre un SEBlock après la convolution 1×1 finale : GlobalAvgPool → FC($C/16$) → ReLU → FC(C) → Sigmoid → recalibrage canal-wise.

Figure 3 — Schéma du bloc Squeeze-and-Excitation (SEBlock).



- **B3** — SE-ResNet-50 from scratch sur HyperKvasir.
- **B4** — SE-ResNet-50 avec transfert des poids ResNet-50 ImageNet (couches compatibles) + fine-tune tête 23 classes.


Hypothèse : le recalibrage canal améliore la robustesse aux variations de couleur (sang, bile, sur/sous-exposition) typiques de l’endoscopie.

4.3 Dual-stream couleur-texture (B5 / B6)

Architecture à deux flux fusionnés par concaténation de features :

- **Flux 1 — RGB** : ResNet-50 backbone $\rightarrow f_{rgb} \in \mathbb{R}^{2048}$.
- **Flux 2 — Couleur-texture** : carte 3 canaux (H du HSV + carte LBP + S du HSV) $\rightarrow$ TextureColorNet léger $\rightarrow f_{tex} \in \mathbb{R}^{512}$.
- **Fusion** : concat $[f_{rgb}; f_{tex}] \rightarrow$ Linear(2560 $\rightarrow$ 23) $\rightarrow$ softmax.

Figure 4 — Schéma dual-stream ResNet + couleur-texture (B5/B6).



Inspiré des approches hybrides LBP/GLCM (Sensors 2022) et dual-stream Effimix (MDPI 2022)

- **B5** — dual-stream from scratch (les deux branches initialisées aléatoirement).
- **B6** — dual-stream avec branche RGB pré-entraînée ImageNet (TextureColorNet scratch).

5. Matériel et méthodes

5.1 Jeux de données et partitions

Kvasir v1 (4 classes) — B0/B1

- Source : téléchargement Simula via `scripts/download_and_prepare_kvasir.py`.
- Volume : 1 400 train / 300 val / 300 test (350/75/75 par classe).
- Classes : cæcum, pylore, polype, ulcère.
- Split stratifié aléatoire (seed 42).

HyperKvasir (23 classes) — B2–B6

- Source : `hyper-kvasir-labeled-images.zip` (~3,9 Go) via `scripts/download_and_prepare_hyperkvasir.py`.
- Layout ImageFolder : `data/hyperkvasir/{train,val,test}/{classe}/`.
- Split stratifié par classe : 70 % train, 15 % val, 15 % test (seed 42).
- Métadonnées : `class_counts.json`, `benchmark_meta.txt`.

Limitation. Partitions au niveau image (pas patient). Les scores reflètent une évaluation recherche, pas une validation clinique prospective.

5.2 Augmentations et prétraitement

Entraînement RGB : recadrage aléatoire, retournements horizontal/vertical, ColorJitter (luminosité, contraste, saturation), normalisation ImageNet (mean/std).

Branche texture (dual-stream) : conversion RGB → HSV, extraction LBP (rayon 1–2, P=8, normalisé), empilement H + LBP + S. Option de précalcul `--precompute-texture` pour accélérer l’entraînement.

5.3 Métriques d’évaluation

Métrique	Rôle
Macro-F1	Objectif principal — sélection checkpoint et reporting
F1 pondéré	Synthèse tenant compte des fréquences de classes
Exactitude (accuracy)	Comparaison avec travaux publiés
Rappel par classe	Sensibilité clinique (polype, œsophagite, grades colite)
Matrice de confusion	4×4 (Kvasir) ou 23×23 (HyperKvasir)
Macro-rappel groupé	Repères / pathologies / procédures teintées / qualité

5.4 Protocole expérimental B0–B6

Tableau 2 — Matrice expérimentale complète.

ID	Architecture	Prétrain	Jeu	Description
B0	ResNet-50	none	Kvasir v1	Baseline scratch — hyperparamètres par défaut
B1	ResNet-50 + Optuna	none	Kvasir v1	HPO baseline — 8 essais, réentraînement 15 époques
B2	ResNet-50	ImageNet	HyperKvasir	Fine-tune transfer learning
B3	SE-ResNet-50	none	HyperKvasir	Recalibrage canal — scratch
B4	SE-ResNet-50	ImageNet	HyperKvasir	SE + transfer learning
B5	Dual-stream couleur-texture	none	HyperKvasir	RGB + HSV/LBP fusion concat
B6	Dual-stream couleur-texture	ImageNet (RGB)	HyperKvasir	Branche RGB pré-entraînée

Hyperparamètres par défaut : scratch — 15–20 époques, AdamW, $\text{lr}=10^{-3}$, batch 16 ; fine-tune — $\text{lr}=10^{-4}$. Sélection par **macro-F1 validation maximale**. Matériel : Apple MPS (AMD Radeon Pro 5300M), repli CPU si instable.

6. Résultats

6.1 Kvasir v1 (4 classes) — résultats réels

Campagne exécutée le 13 juin 2026 sur images endoscopiques réelles Simula.

Tableau 3 — Performance B0 vs B1 sur Kvasir v1 (résultats réels).

Modèle	Partition	Exactitude	Macro-F1	F1 pondéré	Rappel polype	Rappel ulcère
B0 Baseline	val	0,737	0,724	0,724	0,493	0,587
B0 Baseline	test	0,703	0,689	0,689	0,413	0,587
B1 Optuna	val	0,793	0,789	0,789	0,587	0,760
B1 Optuna	test	0,760	0,749	0,749	0,480	0,720

B1 améliore la macro-F1 test de **+0,060** par rapport à B0. Rappels test B1 : pylore 96 %, cæcum 88 %, ulcère 72 %, polype 48 %. Confusions principales : polype↔ulcère (20 polyps classés ulcère sur 75).

Tableau 4 — Matrice de confusion B0 baseline (test). Lignes = vérité, colonnes = prédiction.

	cæcum	polype	pylore	ulcère
cæcum	64	10	0	1
polype	9	31	13	22
pylore	0	0	72	3
ulcère	11	13	7	44

Tableau 5 — Matrice de confusion B1 Optuna (test).

	cæcum	polype	pylore	ulcère
cæcum	66	8	0	1
polype	12	36	7	20
pylore	0	0	72	3
ulcère	12	4	5	54

Figure 5 — Échantillons Kvasir v1 (partition test) et prédictions B1.




Cæcum

Vérité terrain : cæcum
Prédiction B1 : cecum ✓




Pylore

Vérité terrain : pylore
Prédiction B1 : pylorus ✓



Polype

Vérité terrain : polype
Prédiction B1 : polyp ✓



Ulcère

Vérité terrain : ulcère
Prédiction B1 : ulcer ✓

6.2 HyperKvasir (23 classes) — B2–B6

Tableau 6 — Résultats HyperKvasir B2–B6 (test/val).


ID	Architecture	Prétrain	Partition	Exactitude	Macro-F1	F1 pondéré
B2	ResNet-50	ImageNet	val	89,6 %	0.591	0.890
B2	ResNet-50	ImageNet	test	87,9 %	0.585	0.874
B3	SE-ResNet-50	none	val	73,0 %	0.439	0.705
B3	SE-ResNet-50	none	test	72,5 %	0.439	0.700
B4	SE-ResNet-50	ImageNet	val	88,9 %	0.596	0.878
B4	SE-ResNet-50	ImageNet	test	88,2 %	0.577	0.870
B5	Dual-stream	none	val	78,2 %	0.472	0.755
B5	Dual-stream	none	test	75,5 %	0.448	0.726
B6	Dual-stream	ImageNet (RGB)	val	90,1 %	0.596	0.894
B6	Dual-stream	ImageNet (RGB)	test	88,8 %	0.586	0.881

SE-ResNet-50 (B3 / B4). Scratch (B3) : macro-F1 test **0,439** (acc 72,5 %) — nettement inférieur au fine-tune ImageNet. Avec transfer (B4) : macro-F1 test **0,577** (acc 88,2 %), proche du ResNet-50 ImageNet (B2 : 0,585) mais *sans gain* au-delà du pré-entraînement ResNet standard. **RQ3** : le recalibrage canal SE n’améliore pas la macro-F1 par rapport à B2 dans notre protocole 23 classes.

Tableau 6bis — Synthèse test (macro-F1) par famille d’architecture.

Famille	Run	Prétrain	Exactitude test	Macro-F1 test
ResNet-50	B2	ImageNet	87,9 %	0,585
SE-ResNet-50	B3	none	72,5 %	0,439
SE-ResNet-50	B4	ImageNet	88,2 %	0,577
Dual-stream	B5	none	75,5 %	0,448
Dual-stream	B6	ImageNet (RGB)	88,8 %	0,586

Figure 6 — Macro-F1 test HyperKvasir (23 classes) par run B2–B6.



6.3 Comparaison avec l’existant

Tableau 7 — Comparaison littérature avec évaluation du protocole équivalent.

Référence	Métrique	Score publié	Notre résultat	Protocole équivalent ?
SE-ResNet Kvasir v2 (IETA 2024)	Accuracy	~99,7 %	B4 88,2 % acc / 0,577 F1	Non (8 vs 23 classes, feature selection)
Effimix HyperKvasir (MDPI 2022)	Accuracy	~98 %	B6 88,8 % acc	Partiel (dual-stream, splits non documentés)
Hybrid LBP+GLCM (Sensors 2022)	Accuracy	~99 %	B5 75,5 % acc	Partiel (texture explicite, jeu différent)
FRAN dual-branch (2024)	Accuracy	97 %+	B6 88,8 % acc	Non (attention + edge, protocole propre)
HyperKvasir benchmark (Borgli 2020)	Macro-F1	~0,82 (DenseNet-161)	B2 0,585 / B4 0,577	Partiel (23 classes, split image-level)
Baseline interne	Macro-F1 test	—	B0 0,689 / B1 0,749	Oui (Kvasir v1, protocole documenté)

7. Discussion

7.1 Intérêt du SE-ResNet pour la couleur endoscopique

Les images endoscopiques présentent des variations importantes de luminosité, de teinte (sang rouge, bile jaune-verte, muqueuse rose) et de saturation. Les blocs SE recalibrent les canaux de feature maps selon le contexte global de l'image. **Résultats RQ3** : B4 (SE-ResNet ImageNet) atteint 0,577 macro-F1 test vs 0,585 pour B2 (ResNet ImageNet) — *pas de gain mesurable* du recalibrage SE dans notre protocole. B3 scratch (0,439) confirme l'importance du transfer learning. Le SE-ResNet reste pertinent pour l'analyse des confusions par classe (œsophagites, grades colite), mais n'améliore pas la métrique globale sous 15 époques sans HPO dédié.

7.2 Dual-stream texture pour les lésions muqueuses

Sur Kvasir v1, la confusion polype↔ulcère (20 erreurs B1 sur 75 polyps test) suggère que la couleur RGB seule est insuffisante pour discriminer les lésions muqueuses. La branche HSV/LBP capture explicitement les motifs texturaux (LBP) et les composantes couleur (H, S) indépendamment de l'intensité globale. Cette approche s'aligne sur les travaux hybrides LBP/GLCM (Sensors 2022) et les architectures dual-stream Effimix/Fran.

7.3 Limites MPS et reproductibilité matérielle

L'entraînement sur Apple MPS (AMD Radeon Pro 5300M) a montré une instabilité lors des campagnes Optuna longues (essais élagués à macro-F1 $\approx 0,25$, checkpoints corrompus). Mitigation : réentraînement explicite post-HPO, repli `--device cpu` pour les campagnes HyperKvasir. Estimation compute : $\sim 30\text{--}45$ min/modèle/15 époques $\rightarrow \sim 6\text{--}8$ h pour B2–B6.

7.4 Déséquilibre des classes HyperKvasir

HyperKvasir présente un fort déséquilibre (ex. `polyp >> impacted-stool`). L'usage de la macro-F1 comme métrique principale atténue le biais vers les classes majoritaires, mais le rappel des classes rares reste critique cliniquement. Extensions prévues : perte pondérée ou focal loss (phase ultérieure), macro-rappel groupé par catégorie clinique.

8. Plan d'implémentation (6 phases)

Phase	Intitulé	Livrables	Statut
0	Documentation	Revue HTML (ce document), <code>SCIENTIFIC_REVIEW.md</code> , PDF v1.1	Terminé
1	Infrastructure	Registre modèles (<code>--arch</code>), script HyperKvasir 23 classes, dataloader dual-stream	Terminé
2	Modèles	SE-ResNet-50 (B3/B4), dual-stream couleur-texture (B5/B6), fine-tune ImageNet (B2)	Terminé
3	Benchmarks	Entraînement + évaluation B2–B6, export JSON, comparaison littérature	Terminé
4	Mise à jour documentation	Injection résultats HyperKvasir dans HTML, <code>summary.md</code> , régénération PDF v1.1	Terminé
5	Extensions cliniques	Splits patient-level, focal loss, HPO Optuna par architecture, Grad-CAM	Planifié

9. Risques et mitigations

Tableau 8 — Matrice des risques identifiés.

Risque	Mitigation
Instabilité MPS (Optuna/HPO long)	Entraînement <code>--device cpu</code> en fallback ; validation checkpoints via <code>evaluate.py</code> avant rapport
Déséquilibre 23 classes	Weighted CE ou focal loss (phase 5) ; macro-F1 comme métrique principale
Dual-stream lent (LBP online)	Précalcul cartes texture (<code>--precompute-texture</code>) ; TextureColorNet léger
Comparaisons littérature biaisées	Tableau « protocole équivalent ? » (§6.3) avec splits, classes, pretrain, métrique
Pas de split patient HyperKvasir	Documenter comme limitation ; extension patient-level en phase 5

10. Conclusions et perspectives

10.1 Conclusions

- Le pipeline ResNet-50 mono-flux est **validé sur Kvasir v1** : B0 atteint 70,3 % test accuracy (macro-F1 0,689) ; B1 Optuna atteint 76,0 % (macro-F1 0,749, +6 points).
- Le rappel polype (~48 %) reste **insuffisant cliniquement** ; les confusions polype ↔ ulcère motivent l’exploration SE-ResNet et dual-stream.
- Sur HyperKvasir (23 classes), **SE-ResNet-50 ImageNet (B4)** atteint 0,577 macro-F1 test — proche de B2 (0,585) et B6 (0,586), sans avantage net du recalibrage canal.
- Le transfer learning ImageNet améliore fortement chaque architecture (B4 vs B3 : +0,138 F1 ; B2 vs scratch : comparable).
- Cette revue v1.1 documente le plan comparatif complet et les résultats B2–B6 (RQ3–RQ6).

10.2 Perspectives prioritaires

Priorité	Direction
Élevée	HPO Optuna dédié SE-ResNet (B4) et focal loss pour classes rares
Élevée	Grad-CAM / visualisation des poids SE sur confusions chromatiques
Élevée	Splits train/val/test au niveau patient
Élevée	Perte focalisée / pondérée pour classes rares et rappel polype
Moyenne	HPO Optuna par architecture (8 essais max) ; repli CPU si MPS instable
Moyenne	Grad-CAM, visualisation des cartes d’attention SE et branches texture

11. Reproductibilité

Environnement : Python 3.11, PyTorch ≥ 2.11 , torchvision ≥ 0.26 , Optuna ≥ 4 , scikit-learn ≥ 1.5 , scikit-image ≥ 0.24 (gestion via Pixi).

Préparation des données

```
pixi run prepare-kvasir -- --output data/kvasir
pixi run prepare-hyperkvasir -- --output data/hyperkvasir
```

Entraînement Kvasir v1 (B0/B1)

```
pixi run train -- --data-dir data/kvasir --epochs 15 --output checkpoints/kvasir_baseline.pt
pixi run tune -- --data-dir data/kvasir --n-trials 8 --epochs-per-trial 8
pixi run train -- --data-dir data/kvasir --epochs 15 --output checkpoints/kvasir_optuna.pt \
  --lr 3.997e-4 --weight-decay 3.94e-5 --batch-size 16 --label-smoothing 0.095
```

Campagne HyperKvasir (B2–B6)

```
bash scripts/run_hyperkvasir_benchmarks.sh
# ou individuellement :
pixi run train -- --data-dir data/hyperkvasir --arch resnet50 --pretrained --epochs 15 \
  --output checkpoints/hyperkvasir/b2_resnet50_imagenet.pt
pixi run train -- --data-dir data/hyperkvasir --arch seresnet50 --epochs 15 \
  --output checkpoints/hyperkvasir/b3_seresnet50_scratch.pt
pixi run train -- --data-dir data/hyperkvasir --arch dualstream_resnet_color_texture --epochs 15 \
  --output checkpoints/hyperkvasir/b5_dualstream_scratch.pt
```

Évaluation

```
pixi run evaluate -- --checkpoint checkpoints/kvasir_baseline.pt --data-dir data/kvasir
pixi run evaluate -- --checkpoint checkpoints/hyperkvasir/b2_resnet50_imagenet.pt \
  --data-dir data/hyperkvasir --split test \
  --output benchmarks/ml/results/hyperkvasir_b2_test.json
```

Artefacts principaux : models/, script_ResNet.py, training.py, evaluate.py, benchmarks/ml/protocol.md, benchmarks/ml/results/summary.md.

12. Références bibliographiques

- [1] Hu J., Shen L., Sun G. (2018). Squeeze-and-Excitation Networks. *CVPR*.
- [2] He K. et al. (2016). Deep residual learning for image recognition. *CVPR*.
- [3] Tajbakhsh N. et al. (2016). Automated polyp detection in colonoscopy videos. *IEEE TMI*, 35(2), 630–644.
- [4] Pogorelov K. et al. (2017). Kvasir: A multi-class image dataset for GI disease detection. *ACM MMSys*.
- [5] Borgli H. et al. (2020). HyperKvasir, a comprehensive multi-class image and video dataset for gastrointestinal endoscopy. *Scientific Data*, 7, 283.
- [6] Sokolova M., Lapalme G. (2009). A systematic analysis of performance measures for classification tasks. *IP&M*, 45(4), 427–437.
- [7] SE-ResNet for Kvasir v2 (2024). IIETA — classification endoscopique multi-classes.
- [8] Effimix / EfficientNet fusion for HyperKvasir (2022). *MDPI*.
- [9] Hybrid LBP+GLCM+RGB for GI disease classification (2022). *Sensors*.
- [10] FRAN dual-branch attention fusion (2024). Classification Kvasir / HyperKvasir.
- [11] Akiba T. et al. (2019). Optuna: A hyperparameter optimization framework. *KDD*.
- [12] Roberts M. et al. (2017). Common pitfalls in machine learning for medical imaging. *Nature Protocols*.
- [13] Byrne M. F. et al. (2019). Real-time automatic measurement of adenoma detection rate. *Gastroenterology*.

13. Annexes

Annexe A — Liste complète des 23 classes HyperKvasir

1. barretts	13. oesophagitis-b-d
2. bbps-0-1	14. polyp
3. bbps-2-3	15. retroflex-rectum
4. dyed-lifted-polyps	16. retroflex-stomach
5. dyed-resection-margins	17. short-segment-barretts
6. hemorrhoids	18. ulcerative-colitis-0-1
7. ileum	19. ulcerative-colitis-1-2
8. impacted-stool	20. ulcerative-colitis-2-3
9. normal-cecum	21. ulcerative-colitis-grade-1
10. normal-pylorus	22. ulcerative-colitis-grade-2
11. normal-z-line	23. ulcerative-colitis-grade-3
12. oesophagitis-a	

Annexe B — Hyperparamètres Optuna (B1, essai 1 — Kvasir v1)

Hyperparamètre	Valeur optimale
Taux d'apprentissage	$3,997 \times 10^{-4}$
Weight decay	$3,94 \times 10^{-5}$
Taille de batch	16
Optimiseur	AdamW
Planificateur	aucun
Lissage d'étiquettes	0,095
Taille d'image	224 px

Espace de recherche Optuna : lr (log [10^{-5} , 10^{-2-6} , 10^{-2}]

Annexe C — Essais Optuna (phase HPO, Kvasir v1)

Essai	Macro-F1	Optimiseur	Planificateur	Taille	Statut
0	0,585	SGD	cosine	224	complet
1	0,724	AdamW	none	224	meilleur
2	0,250	AdamW	step	256	complet
3–7	$\leq 0,250$	mixte	mixte	mixte	élagué

Annexe D — Échantillons visuels

Échantillons Kvasir v1 réels : docs/assets/pdf_samples/ (cecum.jpg, pylorus.jpg, polyp.jpg, ulcer.jpg).
Échantillons HyperKvasir par groupe clinique : à ajouter post-téléchargement (repère, polype, colite, œsophagite).

Auteur : Hamza AASSIF | **Dépôt :** endoscopy-resnet

Version : revue comparative v1.0 (juin 2026) — plan complet + résultats Kvasir v1

Déclaration : prototype de recherche — non validé pour usage clinique.

Document généré à partir du plan de comparaison SE-ResNet / dual-stream et de benchmarks/ml/results/summary.md.

Archive Kvasir v1 : docs/synthese_benchmark_fr.html (juin 2026).