

Apprentissage profond pour la classification d'images endoscopiques : pipeline ResNet-50 avec optimisation Optuna — synthèse des benchmarks

Hamza AASSIF

Recherche indépendante — projet *endoscopy-resnet*

Juin 2026

RÉSUMÉ

Contexte. L'analyse assistée par ordinateur des images de coloscopie et d'endoscopie digestive haute peut contribuer à la détection des lésions (polypes, ulcères) et à la confirmation des repères anatomiques (cæcum, pylore). Les réseaux convolutifs profonds exigent toutefois des pipelines reproductibles, des métriques adaptées au déséquilibre des classes et une recherche systématique des hyperparamètres.

Objectif. Présenter et évaluer un pipeline reproductible de classification en quatre classes — cæcum, pylore, polype, ulcère — basé sur un ResNet-50 entraîné from scratch, avec sélection du modèle par macro-F1 et optimisation bayésienne via Optuna.

Méthodes. Architecture unifiée pour l'entraînement et l'inférence, protocole de benchmark B0 (baseline) vs B1 (Optuna), espace de recherche à huit dimensions, élagage médian MedianPruner, et évaluation sur partitions validation et test avec rapports JSON standardisés.

Résultats. Sur **Kvasir v1** (1 400 / 300 / 300 images train/val/test, quatre classes équilibrées), le baseline B0 atteint **70,3 % d'exactitude** et une **macro-F1 de 0,689** sur test ; le modèle B1 (Optuna) atteint **76,0 %** et **0,749 macro-F1** (+6,0 points). Rappels test B1 : pylore 96 %, cæcum 88 %, ulcère 72 %, polype 48 %. Confusions principales polype↔ulcère.

Conclusions. L'HPO Optuna améliore les performances sur données réelles, mais la sensibilité polype (~48 %) reste insuffisante cliniquement. Le pipeline est validé de bout en bout sur imagerie endoscopique publique.

Mots-clés : *coloscopie, endoscopie, détection de polype, classification d'ulcère, apprentissage profond, ResNet, aide au diagnostic, optimisation d'hyperparamètres, Optuna, imagerie digestive.*

1. Introduction

1.1 Motivation clinique

Le cancer colorectal demeure une cause majeure de mortalité par cancer. L'efficacité de la coloscopie repose sur l'inspection complète de la muqueuse, la confirmation de l'intubation cæcale et le taux de détection des adénomes (ADR). Les systèmes d'aide à la détection (CAD) analysent les images pour repérer les repères anatomiques et les lésions suspectes. Les réseaux convolutifs atteignent des performances solides sur des jeux publics tels que Kvasir et HyperKvasir.

1.2 Formulation du problème

Chaque image RGB est assignée à l'une de quatre classes :

Classe	Intérêt clinique
Cæcum	Repère de fin de coloscopie
Pylore	Repère anatomique en endoscopie haute
Polype	Lésion précancéreuse — sensibilité critique
Ulcère	Pathologie muqueuse — pertinence diagnostique

1.3 Questions de recherche

- **RQ1** : Un ResNet-50 from scratch peut-il classer de manière fiable ces quatre catégories sous un protocole standardisé ?
- **RQ2** : L'optimisation Optuna améliore-t-elle la macro-F1 par rapport aux hyperparamètres par défaut ?
- **RQ3** : Quels hyperparamètres influencent le plus la performance en validation ?
- **RQ4** : Quelles métriques et stratégies de partitionnement conviennent au reporting clinique ?

1.4 Apports du projet

- Pipeline reproductible avec architecture partagée et checkpoints enrichis (classes, hyperparamètres, métriques).
- Protocole Optuna optimisant la macro-F1, métrique adaptée aux jeux déséquilibrés.
- Harness de benchmark (`benchmarks/ml/`) comparant baseline et modèle optimisé.
- Correction de failles critiques du prototype initial (incompatibilité train/inférence, checkpoints incomplets, sélection par exactitude seule).

2. Matériel et méthodes

2.1 Jeu de données et protocole expérimental

Les images suivent la structure ImageFolder : `train/`, `val/`, `test/` avec un sous-dossier par classe. Campagne principale sur **Kvasir v1** (Simula, 2026) :


- **Source** : téléchargement officiel via `scripts/download_and_prepare_kvasir.py` (datasets.simula.no).
- **Volume** : 350 train / 75 val / 75 test par classe — 1 400 / 300 / 300 images au total.
- **Classes** : cæcum, polype, pylore, ulcère (mapping depuis normal-cecum, polyps, normal-pylorus, ulcerative-colitis).
- **Matériel** : Apple MPS (AMD Radeon Pro 5300M).
- **Date d'exécution** : 13 juin 2026 (Kvasir réel) ; 11 juin 2026 (proxy synthétique, annexe).


Limitation. Partitions au niveau image (pas patient). Les scores reflètent une évaluation recherche sur Kvasir v1, pas une validation clinique prospective.

2.2 Exemples visuels — Kvasir v1 (partition test)

La figure 1 présente des images endoscopiques réelles (Kvasir v1, partition `test/`) avec les prédictions du modèle B1 (ResNet-50, essai Optuna 1, réentraîné 15 époques).

Figure 1 — Échantillons Kvasir v1 et prédictions du modèle B1.





Erreur typique (B1, test) : polype classé ulcère — voir `polyp_test_0003.jpg` (20 confusions polype→ulcère sur 75 polyps test). Les lésions muqueuses partagent des textures proches en imagerie endoscopique.

2.3 Architecture et entraînement

ResNet-50 from scratch (~23,5 M paramètres), blocs Bottleneck, sortie softmax à 4 classes. Augmentations d’entraînement : recadrage aléatoire, retournements, ColorJitter, normalisation ImageNet. Perte : entropie croisée (lissage d’étiquettes optionnel). Sélection du checkpoint par **macro-F1 maximale** sur validation.

2.4 Conditions expérimentales

ID	Description	Configuration
B0	Baseline	15 époques, AdamW, $\text{lr}=10^{-3}$, images 224×224
B1	Optuna (essai 1)	8 essais $\times$ 8 époques/essai ; réentraînement 15 époques avec hparams optimaux
B2	Fine-tuning ImageNet	Prévu — non réalisé

2.5 Optimisation Optuna

Espace de recherche : taux d’apprentissage (log), weight decay (log), taille de batch {8, 16, 32}, optimiseur {AdamW, SGD}, planificateur {none, cosine, step}, lissage d’étiquettes [0, 0,2], taille d’image {224, 256}. Élagueur : MedianPruner (3 essais de démarrage, 2 époques de warmup). Objectif : maximiser la macro-F1 sur validation.

2.6 Métriques d’évaluation

Métrique	Rôle
Exactitude (accuracy)	Reporting standard
Macro-F1	Objectif principal HPO et sélection de modèle
F1 pondéré	Synthèse tenant compte des fréquences
Rappel par classe	Sensibilité clinique (polype, ulcère)
Matrice de confusion	Analyse des confusions anatomiques/pathologiques

3. Résultats

3.1 Performance de classification (B0 vs B1) — Kvasir v1

Tableau 1 — Performance sur Kvasir v1 (13 juin 2026).

Modèle	Partition	Exactitude	Macro-F1	F1 pondéré	Rappel polype	Rappel ulcère
B0 Baseline	val	0,737	0,724	0,724	0,493	0,587
B0 Baseline	test	0,703	0,689	0,689	0,413	0,587
B1 Optuna	val	0,793	0,789	0,789	0,587	0,760
B1 Optuna	test	0,760	0,749	0,749	0,480	0,720

B1 améliore la macro-F1 test de **+0,060** par rapport à B0. Le pylore (96 % rappel test) et le cæcum (88 %) sont bien reconnus ; le polype reste la classe la plus difficile (48 % rappel). Confusions principales : polype↔ulcère (20 polyps classés ulcère sur test, B1).

3.2 Matrice de confusion (B1, test)

Tableau 2 — Matrice de confusion B1 sur test (lignes=vérité, colonnes=prédiction).

	cæcum	polype	pylore	ulcère
cæcum	66	8	0	1
polype	12	36	7	20
pylore	0	0	72	3
ulcère	12	4	5	54

3.3 Analyse des essais Optuna (phase HPO, Kvasir v1)

Tableau 3 — Macro-F1 en validation pendant la recherche (8 époques par essai).

Essai	Macro-F1	Optimiseur	Planificateur	Taille	Statut
0	0,585	SGD	cosine	224	complet
1	0,724	AdamW	none	224	meilleur
2	0,250	AdamW	step	256	complet
3–7	≤0,250	mixte	mixte	mixte	élagué

3.4 Meilleurs hyperparamètres (essai 1)

Hyperparamètre	Valeur optimale
Taux d'apprentissage	$3,997 \times 10^{-4}$
Weight decay	$3,94 \times 10^{-5}$

Taille de batch	16
Optimiseur	AdamW
Planificateur	aucun
Lissage d'étiquettes	0,095
Taille d'image	224 px

3.5 Bilan ingénierie

Problème initial	Impact	Résolution
ResNet custom à l'entraînement, torchvision à l'inférence	Incompatibilité des poids	<code>model.py</code> unifié
Entrées interactives	Non reproductible	Interface CLI
Checkpoint poids seuls	Perte des métadonnées	Checkpoint enrichi
Hyperparamètres fixes	Sous-performance	<code>optuna_search.py</code>
Sélection par exactitude	Biais classe majoritaire	Sélection par macro-F1

4. Discussion

4.1 Interprétation clinique

Les classes repère (cæcum, pylore) soutiennent les indicateurs de qualité procédurale. Les classes pathologiques (polype, ulcère) exigent un reporting séparé du **rappel**. Un modèle très exact sur des images « faciles » mais défaillant sur les polypes serait cliniquement inacceptable.

4.2 Valeur de l'optimisation Optuna

Sur Kvasir v1, l'HPO discrimine nettement les configurations : SGD + cosine n'atteint que 0,585 de macro-F1 (essai 0), tandis qu'AdamW sans planificateur et un taux d'apprentissage modéré ($\sim 4 \times 10^{-4}$) atteint 0,724 en phase de recherche, puis **0,789** en validation après réentraînement 15 époques. Le gain test (+6 points de macro-F1) confirme l'intérêt de l'HPO, mais le rappel polype ($\sim 48\%$) exige des approches complémentaires (pré-entraînement ImageNet, perte focalisée).

4.3 Limites

- Partitions au niveau image — risque de fuite si plusieurs frames proviennent d'une même procédure.
- ResNet-50 from scratch vs pré-entraînement ImageNet (ablation B2 absente).
- Rappel polype insuffisant pour un déploiement clinique ($\sim 48\%$ sur test).
- Instabilité GPU MPS pendant les longues campagnes Optuna (export checkpoint corrompu — contourné par réentraînement explicite).
- Prototype de recherche — non validé pour usage clinique.

4.4 Annexe — proxy synthétique (11 juin 2026)

Smoke test pipeline : 320 images procédurales, B0/B1 à exactitude/macro-F1 = 1,000. Confirme l'ingénierie logicielle uniquement.

5. Conclusions et perspectives

5.1 Conclusions

Le pipeline *endoscopy-resnet* a été validé sur **Kvasir v1** : B0 atteint 70,3 % d'exactitude test (macro-F1 0,689) ; B1 Optuna atteint 76,0 % (macro-F1 0,749, +6 points). Le pylore et le cæcum sont bien classés ; le polype reste difficile (48 % rappel). L'HPO améliore sensiblement la détection des ulcères (+13 points de rappel vs B0).

5.2 Perspectives prioritaires

Priorité	Direction
Élevée	Fine-tuning ImageNet (condition B2) sur Kvasir
Élevée	Splits train/val/test au niveau patient
Élevée	Perte focalisée / pondérée pour améliorer le rappel polype

Moyenne	≥30 essais Optuna ; repli CPU si MPS instable
Moyenne	Grad-CAM, détection/segmentation (U-Net, Mask R-CNN)

6. Reproductibilité

Environnement : Python 3.11, PyTorch ≥2.11, Optuna ≥4, scikit-learn ≥1.5 (Pixi). Artefacts principaux : `model.py`, `script_ResNet.py`, `optuna_search.py`, `evaluate.py`, protocole `benchmarks/ml/protocol.md`, résultats `benchmarks/ml/results/summary.md`.

Références sélectionnées

- [1] Tajbakhsh N. et al. (2016). Automated polyp detection in colonoscopy videos. *IEEE TMI*, 35(2), 630–644.
- [2] Byrne M. F. et al. (2019). Real-time automatic measurement of adenoma detection rate. *Gastroenterology*.
- [4] Pogorelov K. et al. (2017). Kvasir: A multi-class image dataset for GI disease detection. *ACM MMSys*.
- [5] Sokolova M., Lapalme G. (2009). Performance measures for classification tasks. *IP&M*, 45(4), 427–437.
- [6] Borgli H. et al. (2020). HyperKvasir. *Scientific Data*, 7, 283.
- [8] He K. et al. (2016). Deep residual learning for image recognition. *CVPR*.
- [11] Akiba T. et al. (2019). Optuna: A hyperparameter optimization framework. *KDD*.
- [12] Roberts M. et al. (2017). Common pitfalls in ML for medical imaging. *Nature Protocols*.

Auteur : Hamza AASSIF | **Dépôt :** endoscopy-resnet

Déclaration : prototype de recherche — non validé pour usage clinique.

Document généré à partir de docs/SCIENTIFIC_REVIEW.md et benchmarks/ml/results/summary.md — Kvasir v1, juin 2026.